

ПОЛУАВТОМАТИЧЕСКАЯ МОРФОЛОГИЧЕСКАЯ РАЗМЕТКА РУССКО- САНСКРИТСКОГО ПАРАЛЛЕЛЬНОГО КОРПУСА



Рубанова Е. А., БКЛ 161

Научный руководитель - к. ф. н. Сичинава Д. В.

Научный консультант - к. ф. н. Гасунс М. Ю.

Санскритские корпуса

DCS - Digital Corpus of Sanskrit

Internet Sacred Text Archive

श्लोत्र इण्डरश्लोत्र

Developed and Maintained by IIT Kanpur

संस्कृत Documents in Devanagari



Computational Linguistics R&D

School of Sanskrit and Indic Studies

Jawaharlal Nehru University

New Delhi

- санскритские тексты - 4,5 миллиона слов,
650 тысяч строк с грам. разметкой;

- параллельные переводы
с санскрита на английский;

- десятки санскритских комментариев с английскими
переводами “Бхагавадгиты”, упанишад, йога сутр и “Рамаяны”;

- библиотека санскритских источников;

- кафедра компьютерной
санскритской лингвистики.

Цели и задачи исследования

Цель - разработка системы **извлечения** и **обработки санскритских именованных сущностей** из русских переводов древнеиндийских эпосов.

Область применения – морфологическая разметка параллельного корпуса и генерация автоматических указателей к книгам.

Задачи:

- 1) сформулировать **признаки** извлекаемых санскритизмов;
- 2) выявить особенности построения прежних **указателей**;
- 3) рассмотреть существующие **методы извлечения** информации из текста и ее обработки;
- 4) создать **инструмент** извлечения и лемматизации санскритизмов;
- 5) применить созданную систему к обработке текстов для **параллельного корпуса** - соотнести именованные сущности в текстах оригинала и перевода, а также для генерации **автоматических указателей**.

Описание материала

Древнеиндийский эпосы: “Махабхарата” - более 1 200 тысяч слов;

3-й том: 1) “Рамаяна” - более 160 тысяч слов;

2) “Махабхарата” – 210 тысяч слов.

Список Серенсена (S. Sørensen) – 9,5 тысяч имен из Махабхараты.

Список санскритизмов - более 354 тысяч санскритских слов.

Словарь иностранных слов - более 14 тысяч слов [Абрамович 1986].

Объединенный словарь русского языка – более 130 тысяч слов [Зализняк 1977] и [Ефремова 2000].

Морфологический словарь русского языка - более 3 000 тысяч слов (OpenCorpora).

Санскритские именованные сущности (примеры)

Санскритские именованные сущности = санскритизмы*:

- широко распространенные заимствования: *йога, карма, буддизм, сансара, гуру* и т. д.
- мифологические и эпические имена: *Агни, Васушена, Бхишма, Шантану, Гада, Гандхари, Индрасена* и т. д.
- названия растений и животных: *дару, баньян, ковидара, приянгу, чакора* и т. д.
- предметы и термины: *бали, аштакапала, Веды, девадатта, мантры* и т. д.
- географические и этнические названия: *Анга, Бхогавати, андхаки, Видарбха, драмиды* и т. д.

*** Санскритизмы составляют 13% русского перевода древнеиндийского текста**

Санскритские именованные сущности (типы)

- несклоняемые: Читравати, Шатадату, Ашташри, Аю, Прекшади и т. д.

-и / -у / -ю: Видхатри (м. р.), Деваки (ж. р.);
Джишну (м. р.), Кадру (ж. р.);
Ваю (м. р.), Сараю (ж. р.) и т. д.

- склоняемые: Шаунака, Индрасена, брахман, гуны, Вира и т. д.

-а / -я: Аурва (м. р.), Ума (ж. р.);
Ахалья (ж. р.), Виджая (м. р.) и т. д.

Методы извлечения информации из текста

1) rule-based approach

[Трофимов 2014] - словари имен и
регулярные выражения - **90%** точность

2) machine learning

[Подобряев 2013] - модель условных
случайных полей (CRF) - **86%** точность

3) ready-made systems

[Большакова, Ефремова 2015] - GATE,
RCO Pattern Extractor, DSTL, LSPL и Tomita-parser
(ориентация на контекстные правила; использование готовых словарей)

Этапы работы

- I. Тестирование **морфологических анализаторов**
- II. Создание **стеммера** для санскритизмов
- III. Генерация **автоматических указателей**
- IV. Соотнесение санскритских имен в корпусе и **морф. разметка**

Извлечение санскритизмов с помощью морфологических анализаторов (1/3)

1. **py morphology2** и метка *FakeDictionary*.

```
Parse(word='кунти', tag=OpencorporaTag('VERB,perf,transing,impr,excl'), normal_form='кунтити', score=0.31818181818181807, methods_stack=((<FakeDictionary>, 'кунти', 629, 13), (<KnownSuffixAnalyzer>, 'нти')))
```

2. **mystem** и метка *bastard*.

```
{'text': 'рамаян', 'analysis': [{'wt': 0.4778279662, 'lex': 'рамаян', 'gr': 'S,фам,муж,од=им,ед', 'qual': 'bastard'}]}
```

3. **py morphology2** + **mystem** + словарь русского языка.

лемматизация  проверка на вхождение в словарь  сохранение

Извлечение санскритизмов с помощью морфологических анализаторов (2/3)

4. **deeppavlov** + словарь русского языка.

лемматизация  проверка на вхождение в словарь  сохранение

5. **stemmer Snowball** + словарь русского языка.

стемминг  проверка на вхождение в словарь основ  сохранение

6. **py morphology2** и образование словоформ.

генерация словоформ  поиск в тексте

Извлечение санскритизмов с помощью морфологических анализаторов (3/3)

1. **pymorphy2** и метка *FakeDictionary*.
2. **mystem** и метка *bastard*.
3. **pymorphy2** + **mystem** + словарь русского языка.
4. **deeppavlov** + словарь русского языка.
5. **stemmer Snowball** + словарь русского языка.
6. **pymorphy2** и образование словоформ.

	1	2	3	4	5	6
точность	0,77	0,7	0,8	0,93	0,57	0,91
полнота	0,81	0,85	0,81	0,85	0,8	0,85
F-мера	0,79	0,77	0,8	0,89	0,67	0,87

Тестирование анализатора **deerpavlov**

- лемматизация - **47%**: *Буддха* -> *Буддх* (*Буддха*); *Ганами* -> *Ган* (*Гана*).
- определение числа - **99%**: *Махабхараты* - *None* (*Sing*).
- определение падежа - **96%**: *Крита* - *Gen* (*Nom*).
- определение рода - **75%**: *Бхима* - *Fem* (*Masc*), *Картавирия* - *Fem* (*Masc*).

Вывод: можно использовать данные о
падеже и числе из анализа *deerpavlov*.

Создание стеммера для санскритизмов (1/3)

Извлечение санскритизмов

1. Подготовка

- введение правил выделения основы слова;
Ашвинами -> Ашвин; Магха -> Магх; брахманов -> брахман и т. д.
- удаление из корпуса русских слов заимствований;
брахман, йога, Будда, карма и т. д.

Создание стеммера для санскритизмов (2/3)

Извлечение санскритизмов

2. Обработка текста

- выделение основы слова;
- проверка на вхождение в корпус русских слов;
- обработка слов с заглавной буквы;

Яма, Парада, Арка, Куру и т. д.

- сохранение всех подходящих вариантов леммы.

Ираваты – Иравата, Иравати; Ракшасу – ракшас, ракшаса и т. д.

accuracy 98%

Создание стеммера для санскритизмов (3/3)

Определение леммы

- введение дополнительных ограничений на окончания;


Н-р, -ом / -ем – окончания множественного числа.

- выбор леммы по падежу словоформы (*deerpravlōv*).

Н-р, словоформа в номинативе сохраняется как лемма.

accuracy 98%

Схема работы стеммера



Рубрики автоматического указателя

- ашока – «беспечальное», дерево *Jonesia asoka*, или *Saraca indica*, известное красотой своих оранжево-алых цветов и почти круглогодичным цветением
- бакула – *Mimusops elengi*, вечнозеленое дерево с душистыми цветами бледно-зеленого цвета
- бала
- баньян см. вата
- бахупутра
- била
- билва – *Aegle marmelos* (Correa), вид дикой яблони, листья которой используются в церемониях почитания Шивы, незрелые плоды – в народной медицине
- бог (владыка, повелитель) богов

Соотнесение санскритских имен

('[1-4]', [0, 'vaiśampāyana'], [0, 'вайшампаяна])

('[1-4]', [2, 'śaunake'], [4, 'шаунаки])

('[1-4]', [3, 'kuntī'], [7, 'кунти])

('[1-4]', [34, 'yudhiṣṭhira'], [80, 'юдхистхире])

('[1-4]', [35, 'dhaumyo'], [64, 'дхаумья'])

('[5-12]', [9, 'savitā'], [11, 'савитар'])

('[5-12]', [21, 'tejah'], [53, 'теджас'])

('[5-12]', [53, 'bhīmena'], [136, 'бхима'])

tr̥ -> тар

nyū -> нью

ṣ -> ш

jñū -> джню

вайшампаяна сказал: выслушав речь шаунаки, юдхиштхира, сын кунти, сопровождаемый братьями, пошел к своему родовому жрецу и сказал ему: «не следовало бы этим брахманам, усвоившим (учение) вед, сопровождать меня в моем изгнании. многие беды постигли меня, и я не в силах обеспечить им защиту. и оставить их не могу, и даяниями поддерживать не способен. как мне тут быть, да разъяснит почтенный!» на какое-то время дхаумья, достойнейший из блюстителей закона, предался размышлениям, дабы найти путь, согласный с дхармой, а потом отвечал юдхиштхире:

vaiśampāyana uvāca ।

śaunakenaivamuktastu kuntīputro yudhiṣṭhiraḥ ।

purohitamupāgamyā bhrātrmadhye'bravīdidam ॥1

prasthitam mānuyāntīme brāhmaṇā vedapāragāḥ ।

na cāsmi pālāne śakto bahuduhkhasamanvitaḥ ॥2

parityaktum na śaknomi dānaśaktiśca nāsti me ।

kathamatra mayā kāryam bhagavānstadbravītu me ॥3

muhūrtamiva sa dhyātvā dharmenānviṣya tām gatim ।

yudhiṣṭhiramu^{vā}cedam dhaumyo dharmabhṛtām varāḥ ॥4

вайшампаяна сказал: выслушав речь шаунаки, юдхиштхира, сын кунти, сопровождаемый братьями, пошел к своему родовому жрецу и сказал ему: «не следовало бы этим брахманам, усвоившим (учение) вед, сопровождать меня в моем изгнании. многие беды постигли меня, и я не в силах обеспечить им защиту. и оставить их не могу, и даяниями поддерживать не способен. как мне тут быть, да разъяснит почтенный!» на какое-то время дхаумья, достойнейший из блюстителей закона, предался размышлениям, дабы найти путь, согласный с дхармой, а потом отвечал юдхиштхире:

vaiśampāyana u
śaunakenaivamuktastu kuntīp
purohitamupāgāmya bhrātṛma
prasthitam mānuyāntīme brāhmaṇa vedaparagān |
na cāsmi pālāne śakto bahuduhkhasamanvitaḥ ||2
parityaktum na śaknomi dānaśaktiśca nāsti me |
kathamatra mayā kāryam bhagavāṁstadbravītu me ||3
muhūrtamiva sa dhyātvā dharmenānviṣya tām gatim |
yudhiṣṭhiramuṣvācedaṁ dhaumyo dharmabhṛtām varaḥ ||4

Падеж: dat

Род: masc

Число: sing

Лемма:

юдхиштхира

вайшампаяна сказал: выслушав речь шаунаки, юдхиштхира, сын кунти, сопровождаемый братьями, пошел к своему родовому жрецу и сказал ему: «не следовало бы этим брахманам, усвоившим (учение) вед, сопровождать меня в моем изгнании. многие беды постигли меня, и я не в силах обеспечить им защиту. и оставить их не могу, и даяниями поддерживать не способен. как мне тут быть, да разъяснит почтенный!» на какое-то время дхаумья, достойнейший из блюстителей закона, предался размышлениям, дабы найти путь, согласный с дхармой, а потом отвечал юдхиштхире:

vaiśampāyana uvāca |

<u>śaunakenaivam</u>	Лемма:	<u>yudhiṣṭhirah</u>
<u>purohitamupāga</u>	<u>vaiśampāyana</u>	e'bravīdidam 1
<u>prasthitam mānu</u>	Тэги: [n.s.m.]	<u>ā</u> vedapāragāḥ
<u>na cāsmi pālana</u>	Лемма: vac	asamanvitaḥ 2
<u>parityaktum na</u>	Тэги: [3. sg. Perf.]	iśca nāsti me
<u>kathamatra mayā</u>		stadbravītu me 3
<u>muhūrtamiva sa dhyātvā</u>	<u>dharmen</u>	ānviṣya tām gatim
<u>yudhiṣṭhiramuvācedam</u>	<u>dhaumyo</u>	dharmabhṛtām varaḥ 4

Код и материалы исследования

https://github.com/evgeniarubanova/sanskrit_stemmer

Библиография

- Большакова, Ефремова 2015 - Е. И. Большакова, Н. Э. Ефремова. *Инструментальные средства для разработки систем извлечения информации из русскоязычных текстов*. М., 2015.
- Ефремова 2000 - Т. Ф. Ефремова. *Новый словарь русского языка. Толково-словообразовательный*. М.: Русский язык, 2000.
- Зализняк 1977 - А. А. Зализняк. *Грамматический словарь русского языка: Словоизменение*. М.: Русский язык, 1977.
- Подобряев 2013 - А. В. Подобряев. Поиск упоминаний лиц в новостных текстах с использованием CRF модели. // *Труды XV Всероссийской научной конференции RCDL'2013 "Электронные библиотеки: перспективные методы и технологии, электронные коллекции"*. Ярославль, 2013.
- Трофимов 2014 - И. В. Трофимов. Выявление личных имен в новостных текстах на материале коллекций Persons-1000/1111-F. // *Всероссийская научная конференция*, 2014.